Laporan Tugas Kecil 2 IF2211 - Strategi Algoritma Semester II Tahun Ajaran 2021/2022

Implementasi Convex Hull untuk Visualisasi Tes Linear Separability Dataset dengan Algoritma Divide and Conquer

Disusun oleh:

Amar Fadil

13520103

Sekolah Teknik Elektro dan Informatika - Institut Teknologi Bandung

Jl. Ganesha 10, Bandung 4013

Daftar Isi

A. Algoritma Convex Hull.	3
B. Source Code	5
1. lib.py	5
2. utils.py	13
3. types.py	15
4mainpy	15
C. Screenshot	18
1. Dataset iris	18
a) petal length (cm) vs petal width (cm)	18
b) sepal length (cm) vs sepal width (cm)	18
2. Dataset wine	19
a) flavanoids vs nonflavanoid_phenols	19
b) ash vs alcalinity_of_ash	19
3. Dataset breast_cancer	19
a) concavity error vs concave points error	20
b) mean area vs worst area	20
4. Dataset water potability	20
a) pH vs Hardness	21
b) Sulfate vs Conductivity	21
Lampiran	22
Assistant Checklist	22
Link Repository	22

A. Algoritma Convex Hull

Algoritma dalam mencari convex hull disadur dari salindia Algoritma Divide and Conquer Bagian 4 untuk Convex Hull. Ide dasar algoritma ini mirip seperti quicksort. Terdapat dua tahap utama dalam mencari convex hull. Tahapan pertama (implementasi __convexHull pada kelas ConvexHull di modul lib) yang dilakukan program ini adalah sebagai berikut:

- 1. Ambil daftar indeks dari daftar semua titik pada range [0, banyaknya titik).
- 2. [Conquer] Kasus basis 1: Jika terdapat kurang dari 2 titik, tidak melakukan apa-apa.
- 3. [Conquer] Kasus basis 2: Jika terdapat tepat 2 titik, maka vertex pembentuk convex hull adalah dua titik tersebut dan simplices pembentuk convex hull adalah garis yang dibentuk dari dua titik tersebut.
- 4. Jika terdapat lebih dari 2 titik, urutkan titik-titik berdasarkan koordinat x dan y-nya.
- 5. Ambil garis yang terbentuk dari titik pertama dan terakhir yang telah diurutkan (titik pertama berada paling kiri, titik kedua berada paling kanan), tambahkan kedua titik menjadi vertices pembentuk convex.
- 6. Hapus titik pertama dan terakhir pada daftar titik.
- 7. **[Divide]** Bagi titik-titik yang tersisa di daftar titik menjadi dua bagian: sebelah kiri atau sebelah kanan. Untuk setiap titik pada daftar titik, periksa determinan dari titik tersebut ke garis yang dibentuk sebelumnya, jika > 0, kelompokkan menjadi titik di sebelah kiri, jika < 0, kelompokkan menjadi titik di sebelah kanan, jika = 0, abaikan titik karena tak membentuk convex.
- 8. [Conquer] Kasus basis 3: Jika setelah pembagian titik, tidak ada titik yang tersisa (semua titik selain pembentuk garis berada pada garis), maka vertices merupakan kedua titik pembentuk garis tersebut dan simplices merupakan garis tersebut.
- 9. [Combine] Rekursif: Lakukan tahap 2 jika masih ada titik tersisa. Tahap 2 dilakukan sebanyak dua kali, pertama untuk kelompok pertama yang berada di kiri garis, kedua untuk kelompok kedua yang berada di kanan garis. Khusus saat pemanggilan kedua, garis dibalik sehingga dimulai dari titik paling ujung kanan (maks) sampai ke titik paling ujung kiri (min). Hal ini dilakukan untuk melakukan prinsip DIY dengan tidak membagi dua fungsi DnC yang relatif sama, sekaligus menjaga konsistensi pengecekan bagian kiri dan kanan relatif.

Tahapan kedua (implementasi __dnc_convexHull pada kelas ConvexHull di modul lib) menerima sebagian titik yang telah dibagi dengan garis yang mengikutinya. Tahapan kedua yang dilakukan program ini adalah sebagai berikut:

- 1. **[Conquer] Kasus Basis 1**: Jika tidak ada titik tersisa, maka simplices pembentuk convex hull juga termasuk garis pada parameter. Tambahkan garis pada daftar simplices (tidak perlu menambahkan titik pembentuk garis ke dalam daftar vertices, karena pasti sudah ditambah sebelumnya, sehingga tidak terjadi duplikat).
- 2. [Conquer] Kasus Basis 2: Jika hanya ada satu titik tersisa (anggapannya seperti segitiga dengan alas berupa garis pada parameter dan tingginya adalah titik yang tersisa ini), maka simplices pembentuk convex hull juga termasuk dua garis yang dibentuk: dari titik tersisa ke titik awal garis, dan dari titik tersisa ke titik akhir garis. Tambahkan kedua garis pada daftar simplices. Tambahkan juga titik tersisa pada daftar vertices (titik pembentuk garis tidak perlu ditambahkan kembali).
- 3. Jika banyak titik lebih dari 1, cari titik yang memiliki jarak paling jauh dari garis parameter. Misalnya titik ini diberi nama pmax. Pmax ini termasuk dalam vertices convex hull. Tambahkan pmax ke dalam daftar vertices dan hapus pmax dalam daftar titik yang akan dibagi.
- 4. Buat dua garis baru, garis pertama (L1) dimulai dari titik awal garis hingga ke pmax dan garis kedua (L2) dimulai dari pmax hingga ke titik akhir garis.

- 5. [**Divide**] Bagi daftar titik dalam dua bagian, kelompok pertama adalah titik yang berada di luar garis pertama, sedangkan kelompok kedua adalah titik yang berada di luar garis kedua. Untuk semua titik yang akan dibagi:
 - a. Jika determinan antara titik dengan garis pertama > 0 (di luar segitiga/di sisi kiri relatif pada vektor L1), maka titik berada pada kelompok pertama.
 - b. Jika determinan antara titik dengan garis kedua > 0 (di luar segitiga/di sisi kiri relatif pada vektor L2), maka titik berada pada kelompok kedua.
 - c. Untuk titik lain yang tidak memenuhi salah satu syarat diatas, abaikan karena berada di dalam segitiga sehingga tidak mungkin membentuk convex hull.
- 6. [Combine] Rekursif: Lakukan pemanggilan tahap kedua kembali sebanyak dua kali: pertama dengan daftar titik pada kelompok pertama dengan garis pertama, kedua dengan daftar titik pada kelompok kedua dengan garis kedua.

Tahap *conquer* atau penyelesaian subproblem terkecil yakni kasus basis akan selalu memberhentikan jalannya fungsi.

B. Source Code

1. lib.py

```
Main class definitions
import numpy as np
import pandas as pd
from itertools import cycle
from matplotlib import pyplot as plt
from typing import Dict, Iterable, List, Tuple
from myConvexHull.types import Feature, Line, Point, PointIndex, LineIndex
from myConvexHull.utils import det, dist_to_line
class ConvexHull(object):
    def __init__(self, dt: Iterable):
        """Create new convex hull instance.
        It will auto process the data by generating
        the convex hull. Only works for static 2D points.
        Args:
            dt (Iterable): List of 2D points, where each element
        dt: List[Point] = [(p[0], p[1]) for p in dt]
        self.points = dt
        self.vertices: List[PointIndex] = []
        self.simplices: List[LineIndex] = []
        """List of the line/edge in the convex hull. Each element
        self.__convexHull()
    def __dnc_convexHull(self, dt: List[PointIndex], line: LineIndex):
        Args:
```

```
Each element is index to self.points.
    line (List[int, int]): Line to check the points.
        Each element is a pair of index to self.points.
# There are two base cases
if len(dt) == 0:
    self.simplices += [line]
elif len(dt) == 1:
    self.simplices += [
        (dt[0], line[0]),
        (dt[0], line[1]),
    self.vertices.append(dt[0])
    # DIVIDE
    pline = (self.points[line[0]], self.points[line[1]])
    pmax = max(
        dt,
        key=lambda x: dist_to_line(pline, self.points[x])
          Add the point to the vertices list
    self.vertices.append(pmax)
    dt.remove(pmax)
    newline: Tuple[LineIndex, LineIndex] = (
        (line[0], pmax),
        (pmax, line[1]),
    # 2.1. Get the points of both line (remember that the
    pnewline: Tuple[Line, Line] = tuple(
        (self.points[p[0]], self.points[p[1]])
        for p in newline
    # 3. Get the points that are outside both the new line
```

```
dt_split: List[List[PointIndex], List[PointIndex]] = [[], []]
        for p in dt:
            # First line is vector (p1,pmax), so the point outside this
           if det(pnewline[0], self.points[p]) > 0:
                dt_split[0].append(p)
           elif det(pnewline[1], self.points[p]) > 0:
                dt_split[1].append(p)
        self.__dnc_convexHull(dt_split[0], newline[0])
        self.__dnc_convexHull(dt_split[1], newline[1])
def __convexHull(self):
   dt = [i for i in range(len(self.points))]
   # Base case:
   if len(dt) == 2:
        self.vertices = dt
        self.simplices = [(dt[0], dt[1])]
   elif len(dt) > 2:
        dt.sort(key=lambda x: self.points[x])
       line = (dt[0], dt[-1])
        # Both points are the vertex of the hull, so add them
        self.vertices.extend(line)
        pline = (self.points[line[0]], self.points[line[1]])
       dt = dt[1:-1]
```

```
dt_split = [[], []]
            for p in dt:
                d = det(pline, self.points[p])
                if d > 0:
                    dt_split[0].append(p)
                elif d < 0:
                    dt_split[1].append(p)
            # Base case 3
            if len(dt_split[0]) + len(dt_split[1]) == 0:
                # maximum point.
                self.simplices = [line]
                self.vertices = [*line]
                self.__dnc_convexHull(dt_split[0], line)
                # Reverse the order of the line points because we have
                self.__dnc_convexHull(dt_split[1], line[::-1])
# Color cycle constant
COLOR_CYCLE = cycle([
    '#1f77b4', '#ff7f0e', '#2ca02c', '#d62728', '#9467bd',
class LinearSeparabilityDataset(object):
    def __init__(self,
        frame: pd.DataFrame,
        target_names: Iterable,
        feature_names: Iterable=None,
        target_key: str='target',
        backend: ConvexHull=ConvexHull
       Useful to easy visualize the data given their dataset.
```

```
Target is the predicted column (y) of the rows given their
target itself (x). You HAVE to always provide the target
names. If `feature_names` is not provided, then it will
automatically get the column names from the `frame` excluding
the `target_key`.
This class will lazy compute the convex hull, meaning that it
that feature pair.
Make sure:
1. `target_names` has the same length as unique value
2. `feature_names` has the same length as total column
in the `frame` excluding `target_key`.
`target_key` is in the frame.
In any case those condition not met, the program will
raise exception.
Args:
    frame (pd.DataFrame): Dataframe of the dataset.
        It should include both target and its features.
    target_names (np.ndarray): Names of the target.
    feature_names (list): Names of the features.
    target_key (str, optional): Target column name.
        Defaults to 'target'.
    backend (ConvexHull, optional): Convex hull computation
        backend. Defaults to custom ConvexHull.
    ValueError: If the length of `target_names` or
    `feature_names` is not qualified.
    KeyError: If `target_key` not exists in the frame.
if len(target_names) != frame[target_key].nunique():
    raise ValueError(
        "The length of `target_names` should be equal to "
        "the unique value counts on `frame[target_key]` "
        "(Expected {} but got {}).".format(
            frame[target_key].nunique(),
            len(target_names),
if feature names is None:
```

```
feature_names = list(frame.columns)
        feature_names.remove(target_key)
   elif len(feature_names) != len(frame.columns) - 1:
        raise ValueError(
            "The length of `feature_names` should be the same "
            "as the total column in the `frame` excluding "
            "`target_key` (Expected {} but got {}).".format(
               len(frame.columns) - 1,
               len(feature_names),
   if target_key not in frame.columns:
       raise KeyError(
            "The `target_key` should be in the frame."
   self.__convex: Dict[str, List[ConvexHull]] = {}
    """List of convex hull for each target and for each
   self.target_key = target_key
   self.frame = frame
   its features and target.
   self.target_names = target_names
   """List of the target name/label.
   self.feature_names = feature_names
    """List of the feature name/label.
   self.backend = backend
def __getPair(self, pair1: Feature, pair2: Feature) -> Tuple[int, int]:
   It will get a pair of the feature index
   Args:
```

```
Returns:
        Tuple[int, int]: Pair of the feature index.
   return ((
        self.feature_names.index(pair1)
        if isinstance(pair1, str) else pair1,
        self.feature_names.index(pair2)
        if isinstance(pair2, str) else pair2,
def __calculate(self, key:str, p1: int, p2: int) -> None:
    """Calculate the convex hull for each target.
   Args:
        key (str): Key in the dictionary of convex hull.
        p1 (int): First feature index.
        p2 (int): Second feature index.
   self.__convex[key] = []
    for i in range(len(self.target_names)):
        bucket = self.frame[self.frame[self.target_key] == i]
        bucket = bucket.iloc[:, [p1, p2]].values
        self.__convex[key].append(self.backend(bucket))
def getConvex(self, pair1: Feature, pair2: Feature) -> List[ConvexHull]:
   Args:
   Returns:
        List[ConvexHull]: List of convex hull for each target.
    pair1, pair2 = self.__getPair(pair1, pair2)
    key = ';'.join([str(pair1), str(pair2)])
    if key in self.__convex:
        return self.__convex[key]
```

```
self.__calculate(key, pair1, pair2)
    return self.__convex[key]
def visualize(self,
   pair1: Feature,
   pair2: Feature,
   figsize: Tuple[int, int]=(10, 6),
   captions: bool=True,
   xlabel: str=None,
   ylabel: str=None,
   Pair of features can be given by their index or their name.
   Args:
        figsize (Tuple[int, int], optional): Figure size.
        title (str, optional): Title of the figure.
        xlabel (str, optional): Label on the x side of the figure.
            Defaults to None.
        ylabel (str, optional): Label on the y side of the figure.
            Defaults to None.
   # Get the convex of the pair of feature.
   data = self.getConvex(pair1, pair2)
   pair1, pair2 = self.__getPair(pair1, pair2)
   plt.figure(figsize=figsize)
    if captions:
        if xlabel is None:
            xlabel = self.feature_names[pair1]
        if ylabel is None:
            ylabel = self.feature_names[pair2]
        plt.title(title if title else f'{xlabel} vs {ylabel}')
        plt.xlabel(xlabel)
        plt.ylabel(ylabel)
   for i in range(len(self.target_names)):
```

```
# Get current color
col = next(COLOR_CYCLE)
# Get the bucket points
bucket = np.array(data[i].points)
# Visualize the points with scatter plot.
# Label them with its corresponding target name.
plt.scatter(
    bucket[:, 0],
    bucket[:, 1],
    label=self.target_names[i],
    color=col,
)
# Visualize the convex hull.
# Plot the simplices lines from the convex hull.
for simplex in data[i].simplices:
    plt.plot(bucket[simplex, 0], bucket[simplex, 1], color=col)
# Show legends and then show the figure.
plt.legend()
plt.show()
```

2. utils.py

```
Basic utility tools for the library.

Contains many useful functions for processing and computing.

"""

from math import isclose, sqrt

from myConvexHull.types import Vector, Line, Point

def vec_len(v: Vector) -> float:

    """Calculate the length of a vector.

Args:

    v (Vector): Vector reference.

Returns:

    float: Length of he vector.

"""

return sqrt(v[0] ** 2 + v[1] ** 2)

def dist_to_line(l: Line, p: Point) -> float:

    """Calculate the distance between a point and a line.

Original Formula

Distance between a point and a line given the line equation.

d = |am+bn+c|/sqrt(a*a+b*b) ... (1)

where line equation ax + by + c = 0 ... (2)
```

```
Line equation given two points:
    (y-y1)/(x-x1) = (y2-y1)/(x2-x1)
    (y-y1)(x2-x1) = (y2-y1)(x-x1)
   (y1-y2)x + (x2-x1)y - x2y1 + x1y2 = 0 ... (3)
   a = y1-y2
   b = x2-x1
   c = -x2*y1 + x1*y2
   Thus the final distance formula is:
   d = abs(a*m + b*n + c) / sqrt(a^2 + b^2)
       l (Line): Line reference.
       p (Point): Point distance reference.
   Returns:
   a = l[0][1] - l[1][1]
   b = l[1][0] - l[0][0]
   c = -l[1][0] * l[0][1] + l[0][0] * l[1][1]
    return abs(a * p[0] + b * p[1] + c) / vec_len((a, b))
def det(l: Line, p: Point) -> float:
    """Calculate the determinant between a point and a line.
       p (Point): Point determinant reference.
    res = (
       p[0] * l[0][1]
       + l[1][0] * p[1]
        + l[0][0] * l[1][1]
       - l[1][0] * l[0][1]
       - l[0][0] * p[1]
```

```
- p[0] * l[1][1]
)

if isclose(res, 0, abs_tol=1e-13):
    res = 0
return res
```

3. types.py

```
"""
Custom type definitions.
"""
from typing import Tuple, Union

Vector = Point = Tuple[float, float]
PointIndex = int
Line = Tuple[Point, Point]
LineIndex = Tuple[PointIndex, PointIndex]
Feature = Union[int, str]
```

4. __main__.py

```
import argparse
import pandas as pd
from myConvexHull.lib import LinearSeparabilityDataset
parser = argparse.ArgumentParser(
    description=' '.join([
        'It will generate a plot of convex hull given a dataset.',
    ]),
    epilog=' '.join([
        'same time. You always have to specify at least one',
        'of the feature pair you want to visualize.\n\n',
        'If you are using the file input mode, please make sure:\n',
        '(1) The file is in csv format.\n',
        '(2) The file started by a row for header/column name,',
        '(3) There is a column named "target" for the target value.',
        'If the target column name is different, please specify',
        'the target column name with -tk/--target_key option.\n',
        '(4) Target column consist of whole number and cannot be skipped',
        '(e.g. you have 3 rows of values, first target is 1, second',
        'target is 3, and third target is 0, then this data is not valid',
        'because it skipped no. 2).\n',
        '(5) Specify the target names / label by -tn/--target names option.',
```

```
'Target names should be ordered starting from label for target = 0.',
ginput = parser.add argument group('File Dataset Input')
ginput.add_argument('-f', '--file', help='Input datasets file. Should have minimum 3 columns:
2 features and a target.')
ginput.add_argument('-tk', '--target_key', help='Target column name.', default='target')
ginput.add_argument('-tn', '--target_names', nargs='+', help='Target name list, separated by
tinput = parser.add_argument_group('Sklearn Dataset Input')
tinput.add_argument('-n', '--dataset_name', help='Name of the dataset.')
vopt = parser.add argument group('Visualization Options')
vopt.add_argument('-fp', '--feature_pair', nargs=2, action='append', help='Feature pair to
plot. Should be separated by space. You can supply multiple pair of feature.', required=True)
vopt.add_argument('-s', '--size', nargs=2, type=int, help='Figure size (width, height) of the
plot.', default=(10, 6))
vopt.add_argument('-nc', '--no_captions', help='Disable captions (title, x/y label).',
action='store_true')
args = parser.parse_args()
if args.dataset name is None and args.file is None:
    parser.error('Either dataset name or file should be supplied.')
elif args.dataset name is not None and args.file is not None:
    parser.error('Only one mode can be used, either dataset name or file should be supplied
but not both.')
# Load and create visualizer object
vis: LinearSeparabilityDataset = None
if args.dataset_name:
    # Lazy load sklearn datasets
    f = getattr(datasets, f'load_{args.dataset_name}')
        parser.error(f'Dataset with name "{args.dataset_name}" is not exists.')
    data = f(as_frame=True)
        frame=data.frame,
        target_names=data.target_names,
else:
```

```
data = pd.read_csv(args.file)
    data.dropna(inplace=True)
        frame=data,
        target_key=args.target_key,
        target_names=args.target_names,
# Sanitize the feature pair
args.feature_pair = [
        int(fp[i])
        if fp[i].isnumeric()
        else fp[i]
        for i in range(2)
    for fp in args.feature_pair
# Visualize each feature pair
for fp in args.feature_pair:
    vis.visualize(
        fp[0], fp[1],
        figsize=args.size,
        captions=(not args.no_captions),
```

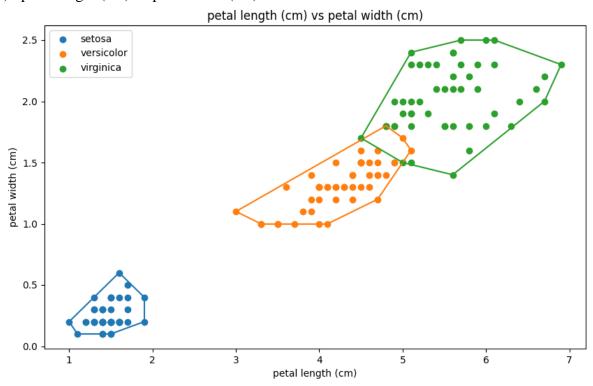
C. Screenshot

1. Dataset iris

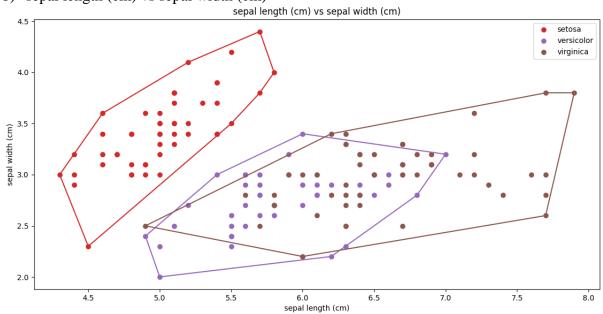
Dua pasang fitur ini dijalankan dengan perintah berikut:

```
python -m myConvexHull -n iris -fp "petal length (cm)" "petal width (cm)" -fp "sepal
length (cm)" "sepal width (cm)"
```

a) petal length (cm) vs petal width (cm)



b) sepal length (cm) vs sepal width (cm)

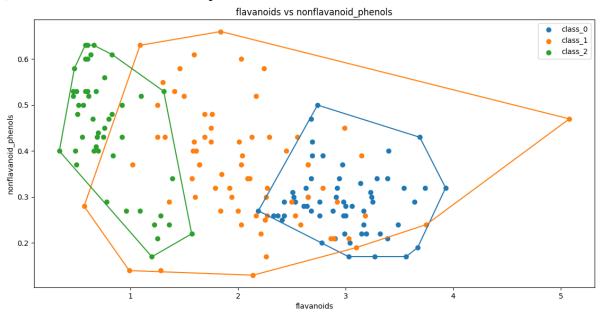


2. Dataset wine

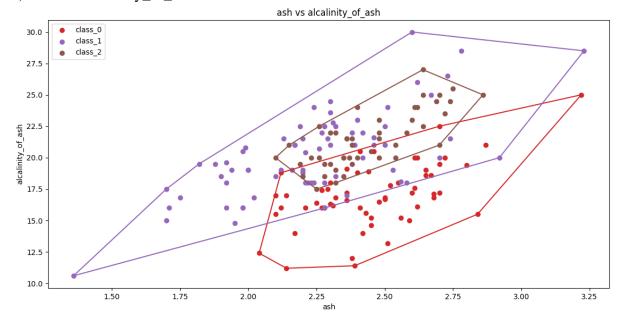
Dua pasang fitur ini dijalankan dengan perintah berikut:

```
python -m myConvexHull -n wine -fp "flavanoids" "nonflavanoid_phenols" -fp "ash"
"alcalinity_of_ash"
```

a) flavanoids vs nonflavanoid_phenols



b) ash vs alcalinity_of_ash

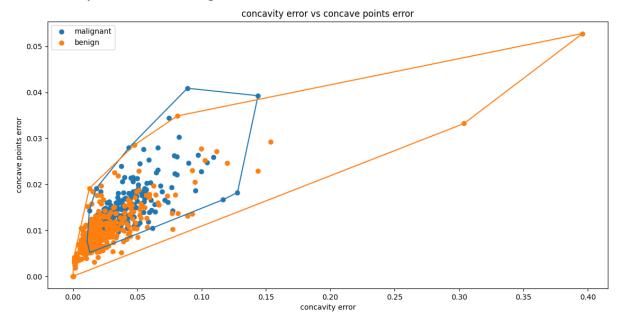


3. Dataset breast_cancer

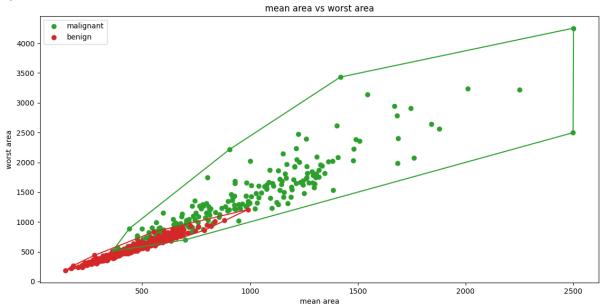
Dua pasang fitur ini dijalankan dengan perintah berikut:

```
python -m myConvexHull -n breast_cancer -fp "concavity error" "concave points error" -fp
"mean area" "worst area"
```

a) concavity error vs concave points error



b) mean area vs worst area

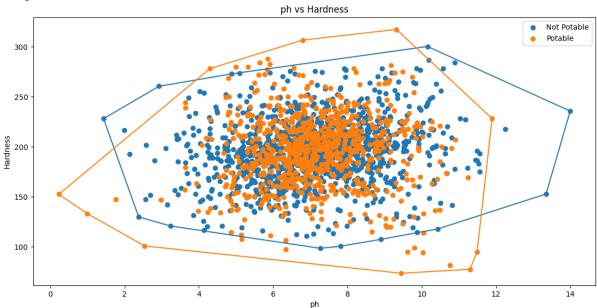


4. Dataset water potability

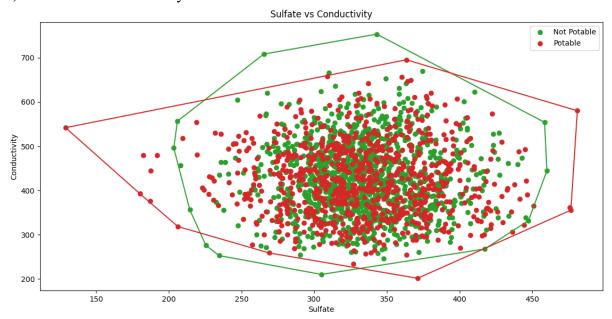
Dataset ini diambil dari open source database di kaggle yang dapat diunduh <u>disini</u>. Dua pasang fitur ini dijalankan dengan perintah berikut:

python -m myConvexHull -f "datasets/water_potability.csv" -tn "Not Potable" "Potable" -tk
"Potability" -fp 0 1 -fp Sulfate Conductivity

a) pH vs Hardness



b) Sulfate vs Conductivity



Lampiran

Assistant Checklist

	Poin	Ya	Tidak
1.	Pustaka <i>myConvexHull</i> berhasil dibuat	2	
	dan tidak ada kesalahan	V	
2.	Convex hull yang dihasilkan sudah benar	$\sqrt{}$	
3.	Pustaka <i>myConvexHull</i> dapat digunakan		
	untuk menampilkan convex hull setiap	$\sqrt{}$	
	label dengan warna yang berbeda.		
4.	Bonus: program dapat menerima input		
	dan menuliskan output untuk dataset	$\sqrt{}$	
	lainnya.		

Link Repository

 $\underline{https://github.com/marfgold1/LinearSeparabilityDataset}$